Fondamenti Teorici e Metodi Computazionali per la Regressione Ortogonale Rigorosa ed Error Analysis

Trattato di Analisi Statistica Sperimentale e Architettura del Codice `FitPipeline`

Laboratorio di Fisica Sperimentale e Computazionale

22 ottobre 2026

Sommario

Questo trattato fornisce una disamina teorica e computazionale completa della stima dei parametri in presenza di errori su entrambe le coordinate (modelli *Errors-in-Variables*). Nella prima parte si analizza l'architettura a tre stadi implementata in `FitPipeline` e l'estensione multicanale a parametri condivisi (`GlobalFitPipeline`). Nella seconda parte viene sviluppata approfonditamente la teoria statistica: dal principio di massima verosimiglianza per variabili vettoriali alla formulazione della regressione ortogonale (ODR), dall'origine geometrica delle degenerazioni periodiche alle dimostrazioni asintotiche del bias da varianza mobile. Si analizza infine la convergenza asintotica della distribuzione chi-quadro, la geometria delle superfici di livello con HESSE e MINOS e la teoria quantitativa dei residui normalizzati (*pulls*).

Indice

1 Architettura e Metodi del Codice `chi_squared_fit.py` 2
- 1.1 Componenti Strutturali e Modelli Dati . . . 2
  - 1.1.1 Contenitori dei Risultati: `ParametroFit` e `RisultatiFit` . . . 2
- 1.2 Formulazione delle Funzioni di Costo per Minuit . . . 2
- 1.3 Pipeline a Singolo Canale (`FitPipeline`) . . . 3
- 1.4 Pipeline Multicanale a Parametri Condivisi (`GlobalFitPipeline`) . . . 3

2 Teoria Statistica Avanzata dei Minimi Quadrati e dell'ODR 4
- 2.1 Derivazione del Principio dei Minimi Quadrati dalla Verosimiglianza . . . 4
- 2.2 Geometria della Proiezione Ortogonale e Degenerazioni Periodiche . . . 4
  - 2.2.1 Origine dell'Aliasing ad Alta Frequenza . . . 5
- 2.3 Dimostrazione Analitica del Bias da Varianza Effettiva . . . 5
  - 2.3.1 Cancellazione del Bias tramite Metodo A . . . 6
- 2.4 Statistica Asintotica della Distribuzione χ^2 e Teorema di Cochran . . . 6
- 2.5 Geometria degli Errori: Curvatura (HESSE) vs Profilazione (MINOS) . . . 6
  - 2.5.1 Approssimazione Parabolica di Secondo Ordine (HESSE) . . . 6
  - 2.5.2 Profilo di Verosimiglianza e Incertezze Asimmetriche (MINOS) . . . 6
- 2.6 Analisi Quantitativa dei Residui Normalizzati (*Pulls*) . . . 7

3 Specifiche delle Classi e API Reference 8
- 3.1 Classe `FitPipeline` . . . 8
  - 3.1.1 Metodo `fit` . . . 8
- 3.2 Classe `GlobalFitPipeline` . . . 8

1 Architettura e Metodi del Codice `chi_squared_fit.py`

L'infrastruttura di fit si prefigge l'obiettivo di automatizzare l'analisi di dati sperimentali bidimensionali garantendo:

1. **Consistenza statistica**: eliminazione del bias asintotico indotto da denominatori mobili nei minimi quadrati generalizzati;
2. **Invarianza globale**: resilienza di fronte a minimi locali spuri o trappole di aliasing periodico tramite discesa stocastica Dual Annealing;
3. **Stima completa delle incertezze**: determinazione della matrice di covarianza asintotica ben condizionata ed estrazione di intervalli di confidenza asimmetrici non lineari con `iminuit`;
4. **Supporto Simultaneo Multicanale**: capacità di vincolare insiemi di dataset eterogenei a parametri globali condivisi.

1.1 Componenti Strutturali e Modelli Dati

1.1.1 Contenitori dei Risultati: `ParametroFit` e `RisultatiFit`

L'incapsulamento dell'output separa rigorosamente le stime paraboliche simmetriche da quelle ottenute esplorando il profilo di verosimiglianza reale:

- `ParametroFit`: dataclass che memorizza il nome del parametro, la stima centrale $\hat{\theta}_j$, l'incertezza simmetrica da matrice di curvatura locale $\sigma_{j,\text{hesse}} = \sqrt{2(\mathbf{H}^{-1})_{jj}}$, le deviazioni asimmetriche $\Delta_{\text{up}}, \Delta_{\text{down}}$ determinate da MINOS, il flag di convergenza `minos_ok`, l'asimmetria assoluta $(\Delta_{\text{up}} - \Delta_{\text{down}})$ e l'indice percentuale:

$$\alpha_j = \frac{\Delta_{\text{up}} - \Delta_{\text{down}}}{\frac{1}{2}(\Delta_{\text{up}} + \Delta_{\text{down}})} \times 100 \tag{1}$$

- `RisultatiFit`: aggrega la lista completa dei parametri, il valore ottimo χ^2_{min}, il chi-quadro ridotto $\chi^2_{\text{rid}} = \chi^2/\nu$, i gradi di libertà $\nu = N_{\text{tot}} - p_{\text{fit}}$, il p-value di significatività asintotica, l'indicatore di validità `valid`, la matrice di covarianza $p \times p$, il vettore dei residui grezzi $r_i = y_i - f(x_i)$, il vettore dei residui normalizzati (*pulls*) $z_i = r_i/\sigma_{\text{tot},i}$, il vettore delle incertezze combinate totali $\sigma_{\text{tot},i}$ e l'istanza interna `Minuit`.

1.2 Formulazione delle Funzioni di Costo per Minuit

Minuit opera con `errordef = Minuit.LEAST_SQUARES` ($\Delta\chi^2 = 1.0$ per la copertura a 1σ). Nel codice sono fornite due classi di costo:

1. `_CostoODR_linearizzato` (Varianza Effettiva Mobile):

$$\chi^2_{\text{eff}}(\boldsymbol{\theta}) = \sum_{i=1}^{N} \frac{(y_i - f(x_i;\boldsymbol{\theta}))^2}{\sigma^2_{y,i} + \left(\left.\frac{\partial f}{\partial x}\right|_{x_i;\boldsymbol{\theta}} \sigma_{x,i}\right)^2} \tag{2}$$

   Le derivate numeriche spaziali $\frac{\partial f}{\partial x}$ vengono ricalcolate a ogni iterazione dell'algoritmo di discesa. Questa dipendenza introduce un termine spuro non nullo nel valore atteso del gradiente, inducendo un bias asintotico sistematico sui parametri.

2. `_CostoODR` (Metodo A a Varianza Congelata - Standard di Laboratorio):

$$\sigma_{\text{tot},i}^2 = \sigma_{y,i}^2 + \left(\left.\frac{\partial f}{\partial x}\right|_{x_i;\mathbf{p}_{\text{ref}}} \sigma_{x,i} \right)^2 = \text{costante} \quad \forall i \tag{3}$$

I pesi vengono pre-calcolati una sola volta sul vettore $\mathbf{p}_{\text{ref}}$ scaturito dalla stima preliminare ODRPACK. Il funzionale:

$$\chi^2(\boldsymbol{\theta}) = \sum_{i=1}^{N} \frac{(y_i - f(x_i;\boldsymbol{\theta}))^2}{\sigma_{\text{tot},i}^2} \tag{4}$$

possiede denominatori numericamente statici: il gradiente è analiticamente non distorto e la matrice Hessiana risulta ben condizionata e simmetrica.

1.3 Pipeline a Singolo Canale (`FitPipeline`)

La classe `FitPipeline` struttura l'ottimizzazione in tre passaggi sequenziali:

1. **Stima Iniziale Locale**: se $\sigma_x > 0$, viene istanziato il modello ODR nativo (`scipy.odr.ODR`) con vettore iniziale $\mathbf{p}_0$; se l'incertezza sull'ascissa è nulla ($\sigma_x \equiv 0$), la stima iniziale ricade sui minimi quadrati ordinari tramite `scipy.optimize.curve_fit`.

2. **Controllo di Consistenza e Ricerca Globale Fallback**: se il pre-fit locale restituisce un chi-quadro ridotto anomalo ($\chi^2_{\text{rid}} > 8.0$) oppure solleva un'eccezione numerica, il controllo passa automaticamente a `_ricerca_globale_fallback`. Questo metodo applica l'algoritmo `dual_annealing` con vincoli adattivi generati da `limits` o centrati sui valori correnti con ampiezza $\pm 5|\mathbf{p}_0|$.

3. **Raffinamento e Diagnostica con iminuit**: i parametri non distorti del pre-fit vengono passati come ancoraggio statico $\mathbf{p}_{\text{ref}}$ a `_CostoODR`. Si eseguono in sequenza `migrad()`, `hesse()` e facoltativamente `minos()`, costruendo infine la struttura completa `RisultatiFit` comprensiva di residui, pulls e varianza efficace σ_{tot}.

1.4 Pipeline Multicanale a Parametri Condivisi (`GlobalFitPipeline`)

Quando si analizzano simultaneamente più serie sperimentali governate da parametri comuni (es. spettri a diverse temperature o curve di risonanza collegate da costanti fisiche identiche), si utilizza la classe `GlobalFitPipeline`:

- Riceve una sequenza di modelli teorici $\{f_k(x;\boldsymbol{\theta})\}_{k=1}^{M}$ e un insieme unificato di parametri $\boldsymbol{\theta}$;
- Esegue una stima iniziale congiunta tramite `scipy.optimize.least_squares` impostato sul metodo robusto Trust Region Reflective (`'trf'`), rispettando i limiti definiti in `limits`;
- Costruisce la funzione di costo unificata `_CostoGlobale`, la quale somma i contributi $\chi^2_k(\boldsymbol{\theta})$ di ciascun dataset garantendo il congelamento della varianza per ogni canale su $\mathbf{p}_{\text{ref}}$;
- Restituisce un'istanza aggregata di `RisultatiFit` in cui residui, pulls e sigma totali risultano opportunamente concatenati su tutto il campione globale.

2 Teoria Statistica Avanzata dei Minimi Quadrati e dell'ODR

2.1 Derivazione del Principio dei Minimi Quadrati dalla Verosimiglianza

Consideriamo un processo di misura in cui sia la coordinata indipendente sia la coordinata dipendente sono grandezze stocastiche. Sia (x_i^*, y_i^*) lo stato vero della natura per l'i-esima osservazione, vincolato a giacere sulla varietà unidimensionale definita dal modello teorico:

$$y_i^* = f(x_i^*; \boldsymbol{\theta}^*) \tag{5}$$

dove $\boldsymbol{\theta}^* \in \mathbb{R}^p$ è il vettore dei parametri fisici veri. L'apparato sperimentale genera una coppia osservata (x_i, y_i) affetta da errori casuali additivi:

$$x_i = x_i^* + \delta_i, \qquad y_i = y_i^* + \epsilon_i \tag{6}$$

Ipotizzando errori gaussiani a media nulla, incorrelati tra punti distinti e incorrelati tra x e y sullo stesso punto, la matrice di covarianza vale:

$$\mathbf{V}_i = \begin{pmatrix} \sigma_{x,i}^2 & 0 \\ 0 & \sigma_{y,i}^2 \end{pmatrix} \tag{7}$$

La funzione di log-verosimiglianza negativa globale $\mathcal{L} = -\ln L$ assume l'espressione:

$$\mathcal{L}(\boldsymbol{\theta}, \mathbf{x}^*) = \frac{1}{2} \sum_{i=1}^{N} \left[\left(\frac{x_i - x_i^*}{\sigma_{x,i}} \right)^2 + \left(\frac{y_i - f(x_i^*; \boldsymbol{\theta})}{\sigma_{y,i}} \right)^2 \right] + \sum_{i=1}^{N} \ln(2\pi \sigma_{x,i} \sigma_{y,i}) \tag{8}$$

Essendo il secondo termine costante rispetto a $\boldsymbol{\theta}$ e $\mathbf{x}^*$, la stima di massima verosimiglianza coincide esattamente con la minimizzazione della somma ponderata degli scarti quadratici:

$$S(\boldsymbol{\theta}, \boldsymbol{\delta}) = \sum_{i=1}^{N} \left[\left(\frac{\delta_i}{\sigma_{x,i}} \right)^2 + \left(\frac{y_i - f(x_i + \delta_i; \boldsymbol{\theta})}{\sigma_{y,i}} \right)^2 \right] \tag{9}$$

avendo definito $\delta_i = x_i^* - x_i$. Nel limite in cui l'incertezza su x sia trascurabile ($\sigma_{x,i} \to 0$), si ha $\delta_i \to 0$, e il funzionale si riduce ai minimi quadrati verticali ordinari (OLS):

$$\lim_{\sigma_x \to 0} S(\boldsymbol{\theta}, \boldsymbol{\delta}) = \chi^2_{\text{OLS}}(\boldsymbol{\theta}) = \sum_{i=1}^{N} \left(\frac{y_i - f(x_i; \boldsymbol{\theta})}{\sigma_{y,i}} \right)^2 \tag{10}$$

2.2 Geometria della Proiezione Ortogonale e Degenerazioni Periodiche

Imponendo la stazionarietà della derivata parziale unidimensionale rispetto a ciascun disturbo δ_i:

$$\frac{\partial}{\partial \delta_i} \left[\left(\frac{\delta_i}{\sigma_{x,i}} \right)^2 + \left(\frac{y_i - f(x_i + \delta_i; \boldsymbol{\theta})}{\sigma_{y,i}} \right)^2 \right] = 0 \tag{11}$$

si ottiene la **condizione geometrica fondamentale di ortogonalità pesata**:

$$\frac{y_i - f(x_i + \delta_i; \boldsymbol{\theta})}{\delta_i} = -\frac{\sigma_{y,i}^2}{\sigma_{x,i}^2} \frac{1}{\left. \frac{\partial f}{\partial x} \right|_{x_i + \delta_i}} \tag{12}$$

Nel piano riscalato delle coordinate adimensionali ($u = x/\sigma_x, v = y/\sigma_y$), il segmento che congiunge il punto misurato al punto vero proiettato sulla curva è perpendicolare al vettore tangente locale.

2.2.1 Origine dell'Aliasing ad Alta Frequenza

Se $f(x;\boldsymbol{\theta})$ include componenti oscillanti (es. $f(x) = A\sin(\omega x + \phi)$), la derivata prima oscilla tra $-A\omega$ e $+A\omega$. L'equazione (12) diviene fortemente multi-modale. Nel limite in cui $\omega \to \infty$, il periodo spaziale $T = 2\pi/\omega$ scende al di sotto del passo sperimentale. Per qualunque dato (x_i, y_i) esiste allora una perturbazione infinitesima $|\delta_i| \leq \pi/\omega \to 0$ tale che $f(x_i + \delta_i) = y_i$. Il costo collassa identicamente a zero ($S \to 0$, $\chi^2_{\text{rid}} \to 0$), intrappolando gli ottimizzatori locali in buche di potenziale non fisiche. Da qui la necessità di imporre limiti fisici (`limits`) sui parametri di frequenza e di disporre del fallback stocastico (`dual_annealing`).

2.3 Dimostrazione Analitica del Bias da Varianza Effettiva

Dimostriamo formalmente l'inconsistenza asintotica del metodo euristico a varianza efficace mobile. Sia la funzione di costo linearizzata:

$$\chi^2_{\text{lin}}(\boldsymbol{\theta}) = \sum_{i=1}^{N} \frac{r_i^2(\boldsymbol{\theta})}{\sigma^2_{\text{eff},i}(\boldsymbol{\theta})} \tag{13}$$

con $r_i(\boldsymbol{\theta}) = y_i - f(x_i;\boldsymbol{\theta})$ e $\sigma^2_{\text{eff},i}(\boldsymbol{\theta}) = \sigma^2_{y,i} + (f_i'(\boldsymbol{\theta})\sigma_{x,i})^2$. Differenziando rispetto al parametro generico θ_j:

$$\frac{\partial \chi^2_{\text{lin}}}{\partial \theta_j} = \sum_{i=1}^{N} \left[\frac{2r_i}{\sigma^2_{\text{eff},i}} \frac{\partial r_i}{\partial \theta_j} - \frac{r_i^2}{\left(\sigma^2_{\text{eff},i}\right)^2} \frac{\partial \sigma^2_{\text{eff},i}}{\partial \theta_j} \right] \tag{14}$$

Poiché $\frac{\partial r_i}{\partial \theta_j} = -\frac{\partial f(x_i;\boldsymbol{\theta})}{\partial \theta_j}$ e $\frac{\partial \sigma^2_{\text{eff},i}}{\partial \theta_j} = 2f_i'(\boldsymbol{\theta})\frac{\partial f_i'(\boldsymbol{\theta})}{\partial \theta_j}\sigma^2_{x,i}$, il gradiente assume la struttura:

$$\frac{\partial \chi^2_{\text{lin}}}{\partial \theta_j} = \underbrace{-2\sum_{i=1}^{N} \frac{y_i - f(x_i;\boldsymbol{\theta})}{\sigma^2_{\text{eff},i}(\boldsymbol{\theta})} \frac{\partial f(x_i;\boldsymbol{\theta})}{\partial \theta_j}}_{G_j(\boldsymbol{\theta})\ \text{(Termine Fisico)}} \underbrace{-2\sum_{i=1}^{N} \frac{(y_i - f(x_i;\boldsymbol{\theta}))^2}{\left(\sigma^2_{\text{eff},i}(\boldsymbol{\theta})\right)^2} \left(f_i'(\boldsymbol{\theta}) \frac{\partial f_i'(\boldsymbol{\theta})}{\partial \theta_j} \sigma^2_{x,i} \right)}_{B_j(\boldsymbol{\theta})\ \text{(Termine di Bias)}} \tag{15}$$

Valutando il valore atteso sul collettivo statistico attorno al valore vero $\boldsymbol{\theta}^*$:

$$\mathbb{E}\left[(y_i - f(x_i;\boldsymbol{\theta}^*))^2\right] = \sigma^2_{\text{eff},i}(\boldsymbol{\theta}^*) \tag{16}$$

Sostituendo in B_j:

$$\mathbb{E}\left[B_j(\boldsymbol{\theta}^*)\right] = -\sum_{i=1}^{N} \frac{1}{\sigma^2_{\text{eff},i}(\boldsymbol{\theta}^*)} \frac{\partial \sigma^2_{\text{eff},i}(\boldsymbol{\theta}^*)}{\partial \theta_j} = -\frac{\partial}{\partial \theta_j} \left(\sum_{i=1}^{N} \ln \sigma^2_{\text{eff},i}(\boldsymbol{\theta}^*) \right) \neq 0 \tag{17}$$

Mentre per il termine coerente $\mathbb{E}[G_j(\boldsymbol{\theta}^*)] = 0$, il gradiente atteso globale al valore vero non si annulla:

$$\mathbb{E}\left[\left. \frac{\partial \chi^2_{\text{lin}}}{\partial \theta_j} \right|_{\boldsymbol{\theta}^*} \right] = -\mathbb{E}\left[B_j(\boldsymbol{\theta}^*)\right] \neq 0 \tag{18}$$

Lo stimatore $\hat{\boldsymbol{\theta}}$ ricavato dall'annullamento del gradiente è **intrinsecamente distorto**: il solutore predilige traiettorie parametriche con pendenze f_i' sistematicamente maggiorate per incrementare i denominatori σ^2_{eff}.

2.3.1 Cancellazione del Bias tramite Metodo A

Nel Metodo A, la derivata viene valutata una sola volta sul vettore di riferimento $\mathbf{p}_{\text{ref}}$ scaturito dal pre-fit:

$$\sigma^2_{\text{tot},i} \equiv \sigma^2_{y,i} + \left(\left.\frac{\partial f}{\partial x}\right|_{x_i;\mathbf{p}_{\text{ref}}} \sigma_{x,i} \right)^2 \implies \frac{\partial \sigma^2_{\text{tot},i}}{\partial \theta_j} \equiv 0 \implies B_j(\boldsymbol{\theta}) \equiv 0 \tag{19}$$

Il termine spuro svanisce identicamente, garantendo convergenza non distorta e proprietà asintotiche ottimali.

2.4 Statistica Asintotica della Distribuzione χ^2 e Teorema di Cochran

Espandendo la funzione modello in serie di Taylor attorno a $\boldsymbol{\theta}^*$:

$$f(x_i;\boldsymbol{\theta}) \approx f(x_i;\boldsymbol{\theta}^*) + \sum_{j=1}^{p} J_{ij}(\theta_j - \theta_j^*), \qquad J_{ij} = \left.\frac{\partial f(x_i;\boldsymbol{\theta})}{\partial \theta_j}\right|_{\boldsymbol{\theta}^*} \tag{20}$$

Definendo la matrice Jacobiana $\mathbf{J} \in \mathbb{R}^{N\times p}$, la matrice diagonale dei pesi $\mathbf{W} \in \mathbb{R}^{N\times N}$ con $W_{ii} = 1/\sigma^2_{\text{tot},i}$, e il residuo linearizzato $\mathbf{r} = \Delta\mathbf{y} - \mathbf{J}\Delta\boldsymbol{\theta}$, la minimizzazione conduce a:

$$\Delta\hat{\boldsymbol{\theta}} = (\mathbf{J}^T\mathbf{W}\mathbf{J})^{-1}\mathbf{J}^T\mathbf{W}\Delta\mathbf{y} \tag{21}$$

Il residuo al minimo vale $\hat{\mathbf{r}} = (\mathbf{I}_N - \mathbf{P})\Delta\mathbf{y}$, con la Hat Matrix $\mathbf{P} = \mathbf{J}(\mathbf{J}^T\mathbf{W}\mathbf{J})^{-1}\mathbf{J}^T\mathbf{W}$. Definendo la variabile standardizzata $\mathbf{z} = \mathbf{W}^{1/2}\Delta\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_N)$, la forma quadratica assume l'aspetto:

$$\chi^2_{\min} = \mathbf{z}^T \left[\mathbf{I}_N - \mathbf{W}^{1/2}\mathbf{J}(\mathbf{J}^T\mathbf{W}\mathbf{J})^{-1}\mathbf{J}^T\mathbf{W}^{1/2}\right]\mathbf{z} = \mathbf{z}^T\mathbf{M}\mathbf{z} \tag{22}$$

La matrice $\mathbf{M}$ è simmetrica e idempotente ($\mathbf{M}^2 = \mathbf{M}$). In virtù del **Teorema di Cochran**, la forma quadratica segue esattamente una distribuzione chi-quadro i cui gradi di libertà corrispondono alla traccia di $\mathbf{M}$:

$$\nu = \text{tr}(\mathbf{M}) = \text{tr}(\mathbf{I}_N) - \text{tr}\left((\mathbf{J}^T\mathbf{W}\mathbf{J})^{-1}(\mathbf{J}^T\mathbf{W}\mathbf{J})\right) = N - p \tag{23}$$

2.5 Geometria degli Errori: Curvatura (HESSE) vs Profilazione (MINOS)

2.5.1 Approssimazione Parabolica di Secondo Ordine (HESSE)

Attorno al punto di stazionarietà $\hat{\boldsymbol{\theta}}$:

$$\chi^2(\boldsymbol{\theta}) \approx \chi^2(\hat{\boldsymbol{\theta}}) + \frac{1}{2}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^T\mathbf{H}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) \tag{24}$$

dove l'Hessiana $\mathbf{H} \in \mathbb{R}^{p\times p}$ definisce l'operatore di curvatura locale. La matrice di covarianza asintotica è $\mathbf{V} = 2\mathbf{H}^{-1}$, con coefficienti di correlazione $\rho_{jk} = V_{jk}/\sqrt{V_{jj}V_{kk}}$. L'errore standard locale coincide con la proiezione ortogonale: $\sigma_{j,\text{hesse}} = \sqrt{V_{jj}}$.

2.5.2 Profilo di Verosimiglianza e Incertezze Asimmetriche (MINOS)

In presenza di forti non linearità parametriche, le superfici equipotenziali subiscono deformazioni asimmetriche. Il metodo MINOS calcola la funzione di profilo unidimensionale:

$$\chi^2_{\text{prof}}(\theta_j) \equiv \min_{\{\theta_k : k\neq j\}} \chi^2(\theta_j, \theta_1, \ldots, \theta_{j-1}, \theta_{j+1}, \ldots, \theta_p) \tag{25}$$

I limiti dell'intervallo di confidenza a 1σ corrispondono alle radici dell'equazione implicita:

$$\chi^2_{\text{prof}}(\theta_j) - \chi^2_{\min} = 1.0 \implies \theta_j^+ = \hat{\theta}_j + \Delta\theta_j^+, \quad \theta_j^- = \hat{\theta}_j - \Delta\theta_j^- \tag{26}$$

generando gli errori asimmetrici $\Delta\theta_j^+ \neq \Delta\theta_j^-$ e quantificando l'asimmetria percentuale α_j.

2.6 Analisi Quantitativa dei Residui Normalizzati (*Pulls*)

La validazione locale della stima richiede l'esame del vettore dei residui normalizzati (pulls) z_i, definiti per ogni punto sperimentale:

$$z_i = \frac{y_i - f(x_i; \hat{\boldsymbol{\theta}})}{\sigma_{\text{tot},i}}, \qquad \sigma_{\text{tot},i} = \sqrt{\sigma_{y,i}^2 + \left(\left.\frac{\partial f}{\partial x}\right|_{x_i;\mathbf{p}_{\text{ref}}} \sigma_{x,i} \right)^2} \tag{27}$$

Se il modello teorico è corretto e le incertezze sperimentali sono distribuite gaussianamente:

$$z_i \sim \mathcal{N}(\mu = 0,\, \sigma^2 = 1) \tag{28}$$

La diagnosi si ricava dai momenti campionari $\bar{z} = \frac{1}{N}\sum z_i$ e $s_z^2 = \frac{1}{N-1}\sum (z_i - \bar{z})^2$:

- $\bar{z} \neq 0$: presenza di offset sistematico non incluso nel modello teorico;
- $s_z^2 \ll 1$: barre d'errore strumentali sovrastimate o modello sovra-parametrizzato (*overfitting*);
- $s_z^2 \gg 1$: incertezze strumentali sottostimate o rumore non gaussiano (outliers);
- Correlazione di segno tra punti successivi: inadeguatezza funzionale della forma teorica adottata.

3 Specifiche delle Classi e API Reference

3.1 Classe `FitPipeline`

```
class FitPipeline:
    def __init__(
        self,
        model: Callable,
        param_names: Sequence[str],
        p0: Sequence[float],
        limits: Optional[dict] = None,
        fixed: Optional[dict] = None,
        run_minos: bool = True,
        verbose: bool = True,
    )
```

3.1.1 Metodo `fit`

```
def fit(
    self,
    x: np.ndarray,
    y: np.ndarray,
    err_x: Optional[np.ndarray] = None,
    err_y: Optional[np.ndarray] = None,
    odr_lin_Newton: bool = True,
) -> RisultatiFit
```

- `odr_lin_Newton = True`: attiva il Metodo A con pesi statici ancorati a $\mathbf{p}_{\text{ref}}$ (consistente e non distorto);
- `odr_lin_Newton = False`: seleziona il metodo linearizzato a varianza mobile (soggetto a bias).

3.2 Classe `GlobalFitPipeline`

```
class GlobalFitPipeline:
    def __init__(
        self,
        models: Sequence[Callable],
        param_names: Sequence[str],
        p0: Sequence[float],
        limits: Optional[dict] = None,
        fixed: Optional[dict] = None,
        run_minos: bool = True,
        verbose: bool = True,
    )

    def fit(
        self,
        xs: Sequence[np.ndarray],
        ys: Sequence[np.ndarray],
        err_xs: Optional[Sequence[np.ndarray]] = None,
        err_ys: Optional[Sequence[np.ndarray]] = None,
        odr_lin_Newton: bool = True,
    ) -> RisultatiFit
```

Consente di fittare M curve simultaneamente. Riceve liste o tuple di array coordinate e propaga l'ottimizzazione Minuit congiunta garantendo il tracciamento unificato di covarianza, gradi di libertà globali e pulls concatenati.